

便利商店最佳化餐食推薦模型

以 MILP 與 GRASP-LS 啟發式並用之決策架構

Group 13: B13705005 宋宇倫、B13705011 陳芄慈、B13705020 陳鼎元、B13705029 蔡冠毅

June 6, 2026

1 Introduction

便利商店是台灣大學生與上班族取得即時餐食的高頻場域：門市密度高、購買流程快速，且商品營養標示相對完整。然而，消費者在挑選餐點時，往往需要同時權衡價格、熱量、蛋白質、糖、鈉與飽足感等多重因素。若僅以「最低價」為準則，容易選到高糖、高鈉的商品；若只追求「健康」，又可能使單餐花費過高。另一方面，便利商店也經常推出「飯糰＋飲料」、「麵食＋蛋」等組合優惠，使實際支付金額取決於是否啟用優惠組合，而非單品原價的簡單加總。

本研究將上述選餐問題建模為一個同時考量優惠組合、個人化營養限制與歷史多樣性懲罰的混合整數線性規劃（MILP）。使用者指定情境模式（輕食／正餐／宵夜）、基本生理資訊（性別、年齡、身高、體重）、活動量與健康目標（維持／減脂／增肌）後，模型會自動推薦一組符合預算、達到基本營養需求，且兼具多樣性的單餐組合。此決策問題的核心 trade-off 包括：

- 成本最小化 vs. 蛋白質最大化（高蛋白食物通常較貴）。
- 嚴格遵守營養區間 vs. 可行解之存在性（限制過嚴時，模型可能無法找到可行解）。
- 短期推薦多樣性 vs. 客觀「最佳」商品反覆被選中。

為兼顧上述目標，本研究在目標函數中加入軟性懲罰項，並以歷史權重 h_i 控制推薦多樣性。考量 MILP 在大型商品集（數百項商品）下可能面臨較長求解時間，本研究另設計啟發式演算法 **GRASP-LS**（Greedy Randomized Adaptive Search Procedure + Local Search），使系統能在毫秒至秒級時間內回傳可行且近似最優的解，並以 Gurobi 解作為基準量化 optimality gap。

2 Problem Description

考慮一位使用者準備在便利商店購買一餐。給定商品集合、各商品價格與營養標示，以及一組「雙品項／三品項」優惠組合，當使用者輸入情境模式、生理資訊、健康目標與預算上限後，系統需決定：

1. 哪些商品以原價單品方式被選入；
2. 哪些優惠組合應被啟用，並將其包含的商品一併納入推薦；
3. 當預算與營養條件相互衝突時，哪些軟性限制可在最小代價下適度鬆弛。

模型輸出為一份單餐推薦清單，並列示其總熱量、蛋白質、脂肪、碳水、糖與鈉含量。模型須同時處理硬性限制（熱量區間、商品數量上限、預算、鈉硬上限、餐型結構——正餐恰含一份主餐與至少一個蛋白質來源、每餐至多一杯飲料與一份甜點）與軟性限制（蛋白質下限、脂肪／碳水區間、糖／鈉上限）。此外，為避免短期內反覆推薦相同商品，模型以分層歷史記憶對近期重複出現的商品與類別施加懲罰。

3 Parameter Preprocessing

使用者輸入無法直接代入 MILP，因此本研究先依 Mifflin–St Jeor 公式將其轉換為單餐營養參數。令年齡 A 、身高 H 、體重 W 、活動係數 $AF \in \{1.2, 1.55, 1.725\}$ 、蛋白質係數 $PF \in \{1.1, 1.6, 1.8\}$ ，

$$\text{BMR} = \begin{cases} 10W + 6.25H - 5A + 5, & \text{男} \\ 10W + 6.25H - 5A - 161, & \text{女} \end{cases}, \quad \text{TDEE} = \text{BMR} \cdot AF,$$

$$\text{Target}_{\text{Cal}} = \text{TDEE} + \delta_{\text{goal}}, \quad \delta = \{0, -500, +300\} \text{ for } \{\text{維持}, \text{減脂}, \text{增肌}\},$$

$$\text{Target}_{\text{Pro}} = W \cdot PF, \quad \text{Target}_{\text{Fat}}^{\min, \max} = \frac{\text{Target}_{\text{Cal}} \cdot FF_{\min, \max}}{9}, \quad \text{Target}_{\text{Carb}}^{\min, \max} = \frac{\text{Target}_{\text{Cal}} \cdot CF_{\min, \max}}{4}.$$

再以情境比例 ρ_m 將每日需求縮放為單餐： $\text{Cal}_m^{\min, \max} = \text{Target}_{\text{Cal}} \cdot \rho_m^{\min, \max}$ ，依此類推。本研究使用 $\rho^{\min, \max}$ 分別為輕食 (0.15, 0.25)、正餐 (0.30, 0.45)、宵夜型 (0.05, 0.15)。

4 Mathematical Model

Sets. I 為商品集合， K 為優惠組合集合， $S_k \subseteq I$ 為組合 k 包含之商品。每項商品依全家官方分類指派一個「餐位角色」 $\text{role}(i) \in \{\text{主餐}, \text{飲料}, \text{甜點}, \text{配菜}\}$ ；令 $I^{\text{main}}, I^{\text{drink}}, I^{\text{dess}} \subseteq I$ 分別為主餐、飲料、甜點集合。 $I^P \subseteq I$ 為「真實蛋白質來源」，定義為每份蛋白質 ≥ 7 g 且非甜點之商品（避免高糖甜點被模型誤判為蛋白質來源）。

Parameters. c_i 單品原價； $\text{cal}_i, \text{pro}_i, \text{fat}_i, \text{carb}_i, \text{sug}_i, \text{sod}_i$ 為商品 i 之營養含量； c_k^{promo} 為優惠價； B 為預算； $\text{Cal}_m^{\text{min,max}}, P_m^{\text{min}}, \dots$ 為單餐限制（見 §3）； N_m^{max} 為商品數上限； h_i 為歷史重複懲罰權重； α, β, γ 與 λ_* 為目標函數權重。

Decision Variables.

$$a_i \in \{0, 1\} \text{ 單品選取, } y_k \in \{0, 1\} \text{ 組合啟用, } x_i = a_i + \sum_{k: i \in S_k} y_k \text{ (輔助).}$$

鬆弛變數： $s_P, s_F^-, s_F^+, s_C^-, s_C^+, s_{\text{Sug}}, s_{\text{Sod}} \geq 0$ 。

Tiered Historical Penalty. 為兼顧「短期不重複」與「久遠商品可再次出現」，本研究將近期推薦過的去重商品，依其「新近排名」 r 放入一個仿作業系統多層回饋佇列（MLFQ）的分層結構。排名落入不同區間對應不同階層 $t(r)$ ，懲罰權重 $w(r) = \omega_{t(r)}$ 隨階層遞減：本研究取邊界 $r \leq \{3, 8, 16, 30\}$ 、權重 $\omega = (5, 2.5, 1, 0.3)$ 。最近被推薦的商品位於最上層（懲罰最重），若接下來數餐未再被選中，懲罰即逐層淡出；若再次被推薦，則回到最上層（promotion）。保留至 $r \leq 30$ ，更久者丟棄，等效於「極長但有限」的記憶窗。則

$$h_i = \sum_r w(r) \mathbf{1}(i \text{ 出現於第 } r \text{ 近的紀錄}).$$

此外定義「類別多樣性懲罰」 $g_i = \sum_r w(r) \mathbf{1}(\text{role}(\text{紀錄}_r) = \text{role}(i))$ ，使剛被推薦過的類別整體受到抑制，避免模型僅透過「更換同類商品變體（如不同品牌豆漿）」製造表面上的多樣性。

Objective.

$$\begin{aligned} \min \alpha & \left(\sum_{i \in I} c_i a_i + \sum_{k \in K} c_k^{\text{promo}} y_k \right) - \beta \sum_{i \in I} \text{pro}_i x_i + \gamma \sum_{i \in I} h_i x_i + \gamma_{\text{cat}} \sum_{i \in I} g_i x_i \\ & + \lambda_P s_P + \lambda_F^- s_F^- + \lambda_F^+ s_F^+ + \lambda_C^- s_C^- + \lambda_C^+ s_C^+ + \lambda_{\text{Sug}} s_{\text{Sug}} + \lambda_{\text{Sod}} s_{\text{Sod}}. \end{aligned} \quad (1)$$

Constraints.

$$a_i + \sum_{k: i \in S_k} y_k \leq 1, \quad \forall i \in I, \quad (\text{C1: 互斥})$$

$$\sum_{i \in I} c_i a_i + \sum_{k \in K} c_k^{\text{promo}} y_k \leq B, \quad (\text{C2: 預算})$$

$$\text{Cal}_m^{\text{min}} \leq \sum_{i \in I} \text{cal}_i x_i \leq \text{Cal}_m^{\text{max}}, \quad (\text{C3: 熱量區間 (硬)})$$

$$\sum_{i \in I} \text{pro}_i x_i + s_P \geq P_m^{\text{min}}, \quad (\text{C4: 蛋白質 (軟)})$$

$$\sum_{i \in I} \text{fat}_i x_i + s_F^- \geq \text{Fat}_m^{\text{min}}, \quad \sum_{i \in I} \text{fat}_i x_i - s_F^+ \leq \text{Fat}_m^{\text{max}}, \quad (\text{C5: 脂肪 (軟)})$$

$$\sum_{i \in I} \text{carb}_i x_i + s_C^- \geq \text{Carb}_m^{\text{min}}, \quad \sum_{i \in I} \text{carb}_i x_i - s_C^+ \leq \text{Carb}_m^{\text{max}}, \quad (\text{C6: 碳水 (軟)})$$

$$\sum_{i \in I} \text{sug}_i x_i - s_{\text{Sug}} \leq \text{Sugar}_m^{\text{max}}, \quad \sum_{i \in I} \text{sod}_i x_i - s_{\text{Sod}} \leq \text{Sodium}_m^{\text{max}}, \quad (\text{C7-8: 糖/鈉 (軟)})$$

$$\sum_{i \in I} \text{sod}_i x_i \leq \kappa \cdot \text{Sodium}_m^{\text{max}}, \quad (\kappa = 1.5) \quad (\text{C8b: 鈉硬上限})$$

$$1 \leq \sum_{i \in I} x_i \leq N_m^{\text{max}}, \quad (\text{C9: 數量})$$

$$\sum_{i \in I^{\text{drink}}} x_i \leq 1, \quad \sum_{i \in I^{\text{dess}}} x_i \leq 1, \quad (\text{C10: 餐型結構})$$

$$\sum_{i \in I^{\text{main}}} x_i = 1, \quad \sum_{i \in I^P} x_i \geq 1, \quad \text{當 } m = \text{正餐模式}. \quad (\text{C11: 主餐 + 蛋白})$$

其中，(C8b) 為鈉含量的硬性上限：雖然軟限制 (C8) 允許鈉含量略高於目標值，但任何一餐都不得超過 $1.5 \times$ 上限，以避免推薦過鹹的組合；(C10) 限制每餐至多一杯飲料與一份甜點；(C11) 要求正餐恰含一份主餐，並至少包含一個真實蛋白質來源，以排除「以三件零食或兩瓶飲料湊成一餐」或「甜點當主菜」等不合理組合。

權重的意義：各目標的相對重要性。目標函數中的權重用來控制各目標的相對重要性： α 對應成本、 β 對應蛋白質、 γ (與 γ_{cat}) 對應重複性，各 λ_* 則對應各項軟限制被違反的程度。預設 $(\alpha, \beta) = (1, 0.5)$ 設定成本與蛋白質之間的權衡幅度， $\lambda_P = 6$ 、 $\lambda_{\text{Sug}} = 4$ 、 $\lambda_{\text{Sod}} = 0.15$ 則決定蛋白質不足、糖與鈉超標各自的懲罰強度。如此可將「健康 vs. 成本」的取捨參數化，使用者可透過 App slider 直接調整偏好 (見 §7 之敏感度分析)。

5 Proposed Algorithm: GRASP-LS

為降低大規模情境下單純依賴商業 solver 的求解負擔，本研究設計啟發式演算法 **GRASP-LS**。此方法結合「貪婪隨機構造 (GRC)」與「鄰域局部搜尋 (LS)」，並透過多重啟動 (multi-start) 強化全域探索能力。整體流程見圖 1 與演算法 1。

核心想法。

1. 綜合優先分數 $\sigma(p)$ (式 2) 同時量化每項商品的蛋白質貢獻、價格負擔、營養適配度、類別獎勵與歷史懲罰，使後續貪婪建構更具方向性。
2. **RCL (Restricted Candidate List)** 機制以參數 $\alpha_{\text{rcl}} \in [0.1, 0.4]$ 控制隨機性： $\alpha_{\text{rcl}} \rightarrow 0$ 偏向純貪婪， $\alpha_{\text{rcl}} \rightarrow 1$ 偏向純隨機；每次 restart 皆隨機抽取候選項，以產生不同的起始解。
3. 組合作為「超商品」，第一步以正比於組合分數的機率嘗試納入一個優惠組合，使啟發式能主動探索「優惠組合—單品選取互斥」的決策邊界。
4. 結構感知建構，建構階段先放入恰好一份主餐，並於加入後續候選時即時遵守「至多一杯飲料、至多一份甜點」之餐型限制 (C10–C11)，使初始解在結構上即具可行性，降低事後仰賴局部搜尋修補的需求。
5. 局部搜尋使用 1-1 swap、1-0 drop、0-1 add 與 combo-swap 等多種移動，採用「首改善 (first-improvement)」策略加速搜尋並降低停滯風險。
6. 多重啟動對 $K_{\text{restart}} = 25$ 個不同種子分別執行 GRC+LS，蒐集所有 hard-feasible 解形成解池，回傳目標函數值最小者 (或依下述 ϵ -最佳取樣回傳一個多樣化解)。

$$\sigma(p) = \beta \cdot \text{pro}_p - 0.06\alpha \cdot c_p - \gamma h_p - 0.6 \frac{\text{cal}_p}{\text{Cal}_{\text{max}}} - \lambda_{\text{Sod}} \frac{\text{sod}_p}{\text{Sodium}_{\text{max}}} - \lambda_{\text{Sug}} \frac{\text{sug}_p}{\text{Sugar}_{\text{max}}} + B_{\text{cat}}(p). \quad (2)$$

其中 $B_{\text{cat}}(p) = 1.2 \cdot \mathbf{1}(p \in I^S) + 1.5 \cdot \mathbf{1}(p \in I^P)$ 。




Figure 1: GRASP-LS 整體流程：多重啟動下，每輪以 GRC 建構結構可行的初始解，經局部搜尋改良後更新解池；重複 $K_{\text{restart}} = 25$ 次後回傳最佳解（部署時改自 ϵ -最佳解池取樣以增多樣性，緊預算無解時退回 MILP）。

Algorithm 1 GRASP-LS for the Convenience Store Meal Recommendation Problem

Require: Instance $\mathcal{I} = (I, K, S)$; 單餐限制 $\mathcal{M}$; 權重 w ; 預算 B ; 重啟次數 K_{restart}

```
1:  $s^* \leftarrow \emptyset$ ;  $z^* \leftarrow +\infty$ 
2: for  $r = 1$  to  $K_{\text{restart}}$  do
3:    $\alpha_{\text{rcl}} \sim \mathcal{U}(0.10, 0.40)$ 
4:    $s \leftarrow \text{GREEDYRANDOMCONSTRUCT}(\mathcal{I}, \mathcal{M}, w, B, \alpha_{\text{rcl}})$  ▷ 含「先試組合再加單品」分支
5:    $s \leftarrow \text{LOCALSEARCH}(s, \mathcal{I}, \mathcal{M}, w, B)$  ▷ 1-1 swap / 1-0 drop / 0-1 add / combo-swap, 首改善
6:    $z \leftarrow \text{EVALUATE}(s)$ 
7:   if  $s$  是 hard-feasible 且  $z < z^*$  then  $s^* \leftarrow s$ ;  $z^* \leftarrow z$ 
8:   end if
9: end for
10: return  $(s^*, z^*)$ 
```

時間複雜度. GRC 每一步檢視 $O(|I|)$ 候選並計算貢獻, 最多取 $N_m^{\max}$ 項, 故 $O(N_m^{\max} \cdot |I|)$. LS 每輪 1-1 swap 約為 $O(N_m^{\max} \cdot |I|)$; 最壞情況下每輪都會改善並進入下一輪. 實務上 LS 經過 $T \leq 10$ 輪即收斂, 總時間為 $O(K_{\text{restart}} \cdot T \cdot N_m^{\max} \cdot |I|)$.

Algorithm 2 Greedy Randomized Construction (GRC) sub-procedure

Require: Instance、單餐限制、RCL 參數 α_{rcl}

```
1:  $s \leftarrow \emptyset$ 
2: if  $\text{Rand}() < 0.6$  then
3:   計算每個 combo  $k$  的  $\sigma_k$ ; 取分數最高的  $\alpha_{\text{rcl}}$ -RCL, 隨機抽  $k^*$  加入  $s$  ▷ 若  $|S_{k^*}| \leq N_m^{\max}$ 
4: end if
5: while  $|s| < N_m^{\max}$  do
6:   篩出未覆蓋、加入後不破預算且不超過  $\text{Cal}_m^{\max}$  的候選  $C$ 
7:   if  $C = \emptyset$  then break
8:   end if
9:   if  $\sum \text{cal}_i$  已  $\geq \text{Cal}_m^{\min}$  且  $|s| \geq 2$  then
10:    嘗試 top-3 候選; 只有當目標函數改善時才加入, 否則 break
11:   else
12:    依  $\sigma$  分數取  $\alpha_{\text{rcl}}$ -RCL, 隨機抽一項加入  $s$ 
13:   end if
14: end while
15: return  $s$ 
```

多樣化部署: ϵ -最佳取樣與後備求解. 若系統每次都回傳唯一最佳解, 連續查詢容易得到幾乎相同的餐點 (MILP 為確定性, 僅靠歷史懲罰輪替). 本研究因此將「多樣性」形式化為對 ϵ -最佳解集合 $\mathcal{S}_\epsilon = \{s : z(s) \leq z^* + \epsilon\}$ 之均勻取樣: 每次查詢皆自解池中, 隨機抽取一個目標值落在最佳值 ϵ 元以內的解作為推薦結果. ϵ 直接控制「多樣性 vs. 最佳性」之 trade-off (量化見 §7 之「多樣性的代價」). 部署時預設以 GRASP-LS ($\epsilon = 8$) 提供多樣化推薦; 若於極緊預算下 GRASP 偶未找到可行解, 則退回 MILP 精確求解作為後備, 確保只要存在可行解, 系統即可回傳推薦結果。

6 Data Collection and Generation

Real-world data scraping (兩階段). 階段一: 營養標示. 本研究透過全家便利商店「食在購安心」食品履歷查詢 API (foodsafety.family.com.tw/Web_FFD_2022/ws/QueryFsProductListByFilter 與 [QueryFsProductByItem](https://foodsafety.family.com.tw/Web_FFD_2022/ws/QueryFsProductByItem)) 爬取 581 項真實商品的官方營養標示, 覆蓋 22 個原始分類. 所有商品的熱量、蛋白質、脂肪、碳水、糖與鈉資料皆來自官方食品履歷的逐包標示, 並以「本包裝含 n 份」自動換算為每包總量. scraper 程式碼見 `src/scrape_familymart.py`.

階段二: 價格. 食品履歷 API 不提供價格. 本研究先解析「全家鮮食組合餐促銷頁」(nevent.family.com.tw/freshfood/) 之 49/59/69/79/99/109 元六個分級, 以 n-gram fuzzy 字串相似度對應, 命中 124 項鮮食 (飯糰、便當、三明治、義大利麵、麵包) 之真實店內價. 其餘非鮮食品項 (乳製品、飲料、零食、冷凍食品等) 全家並無公開的「單品店內價」API——「全家行動購」電商目錄雖可爬取 (fts-api.91app.com), 但其中 78% 為整箱/多入裝 (價格中位數 NT\$149), 屬於「整箱價」而非「單品店價」, 若直接採用將嚴重扭曲單餐

Algorithm 3 Local Search (1-1 swap / 1-0 drop / 0-1 add / combo-swap)

Require: 解 s 、最大輪數 $T_{\max}$

```
1: for  $t = 1$  to  $T_{\max}$  do
2:   improved  $\leftarrow$  false
3:   for all  $p \in s, p' \notin s$  do
4:     if 以  $p'$  取代  $p$  後可行且目標下降 then
5:        $s \leftarrow s \setminus \{p\} \cup \{p'\}$ ; improved  $\leftarrow$  true; break to outer
6:     end if
7:   end for
8:   if not improved then 嘗試 1-0 drop; 0-1 add; combo-swap
9:   end if
10:  if 該輪無任何改善 then break
11:  end if
12: end for
13: return  $s$ 
```

定價（如一碗牛肉麵被標為 NT\$249）。本研究因此對其餘 457 項採「市售行情校正價」：依分類建立合理的單份店價基準（乳製品約 28、單瓶豆漿約 28、關東煮每串約 20、舒肥雞胸約 59 等），並對標有容量之飲料按毫升微調。最終價格組成為 124 項鮮食實價 + 457 項市售校正價（程式碼 `src/scrape_freshfood_prices.py`、`src/curate_prices.py`）。因此，本研究明確標註資料來源：鮮食採真實分級價，其餘商品則採依市場行情校正之合理估計價。

階段三：份量正規化、家庭份過濾與角色標記。許多 SKU 為多份包裝（1857 ml 豆漿 = 4 份、24 入禮盒等），其營養與價格為「整包」數值而非一餐所含；本研究將所有數值除以份數正規化為「每份」，並對每份價格設下限 NT\$18，避免因整包均價被低估而產生「一份僅 1 元」的假性低價商品，進而不合理地主導推薦結果。家庭份（ ≥ 3 份，如 1857 ml 大瓶、936 ml 牛乳）並非合理的單餐購買，因此自商品池中移除，581 項過濾後為 488 項。此外，原始 CSV 以關鍵字推得的 `is_main/is_protein` 旗標雜訊偏高（蛋糕、餅乾曾被標為蛋白質來源），本研究改以官方分類重新指派餐位角色（主餐／飲料／甜點／配菜），並將糖 ≥ 10 g 之甜麵包（菠蘿、拔絲等）改判為甜點，使「真實蛋白質來源」與「主餐」的定義更貼近實際消費情境（程式碼 `src/data_loader.py`）。

組合優惠。共 55 組由 `main + drink`、`main + side`、`main + side + drink` 三類規則合成的優惠組合，折扣率設為 17%–20%；此部分屬 `mock` 設定，本研究已於報告中明確標示。

Real-world user profiles. 為展示模型在不同使用者條件下的推薦差異，本研究設計 6 個典型 profile（性別 $\times$ 健康目標 $\times$ 活動量），各搭配 3 種情境模式，共 18 個 real-world 例題（見表 1）。

Random instances. 為驗證可擴展性，本研究依下列因子建立隨機例題：商品數 $|I| \in \{30, 50, 80, 120, 200, 300\}$ ；組合數 $|K| \in \{8, 15, 25, 35, 60, 90\}$ ；各規模 5 個隨機種子，共 30 個隨機例題。商品屬性分布如下： $cal \sim \mathcal{U}(180, 650)$ （主食）或 $\mathcal{U}(15, 320)$ （非主食）， $pro \sim \mathcal{U}(5, 30)$ （含蛋白質）或 $\mathcal{U}(0, 10)$ ， $sod \sim \mathcal{U}(0, 1400)$ ；組合大小 $\in \{2, 3\}$ ，折扣率 $\sim \mathcal{U}(0.80, 0.92)$ 之原價。

壓力測試情境（**factorial scenario design**）。上述隨機例題主要改變「規模」此一因子。為進一步檢驗 GRASP-LS 在極端條件下的穩健性，本研究另設計一組 2×2 因子情境：因子一為預算水準（緊 $B = 90$ / 寬 $B = 220$ ），因子二為蛋白質目標（高：增肌目標 / 寬鬆：維持目標）；於 3 種規模（80 / 120 / 200 品項） $\times$ 4 個種子下交叉，共 $4 \times 3 \times 4 = 48$ 個受測例題，各情境同時以 MILP 與 GRASP-LS 求解（程式碼 `src/run_extra_experiments.py`）。結果見 §7.3。

7 Performance Evaluation

本節以三種解法相互比較：(i) **Gurobi MILP**（精確解，作為上下界基準）；(ii) **GRASP-LS**（本研究提出之啟發式）；(iii) **Greedy baseline**（最簡單之「蛋白質／價格比」貪婪法，作為「very simple heuristic」基準）。權重設定為 $\alpha = 1, \beta = 0.5, \gamma = 2, \gamma_{\text{cat}} = 8, \lambda_P = 6, \lambda_P^{\pm} = 2/3, \lambda_C^{\pm} = 1/1.5, \lambda_{\text{Sug}} = 4, \lambda_{\text{Sod}} = 0.15$ 。基準表（MILP/GRASP/Greedy 比較）皆以空歷史求解，故 $\gamma, \gamma_{\text{cat}}$ 不影響最佳值；多樣性效果另於 §7 之敏感度與「多樣性的代價」中另行評估。

7.1 Real-world Instances

表 1 為六個真實使用者 × 三種情境的結果。MILP 在 18 個真實例題中皆求得全域最佳解；GRASP-LS 亦達到 **100% hard-feasible**，平均 optimality gap 為 **7.1%**，其中 12/18 例題 gap 為 0%。值得注意的是，非零 gap 全部集中於「正餐」情境——加入「恰一份主餐 + 餐型結構」(C10–C11) 後，正餐之可行組合較窄，GRASP 之 1-1 swap 鄰域偶會卡在次優（最差 U5 女·維持·正餐 40.5%）；輕食與宵夜型則全部 0%。相對地，**Greedy baseline** 在新的結構與鈉硬上限下 **0%** 可行：它以「蛋白質／價格比」貪取小型高蛋白品，必然缺主餐（違反 C11）且鈉常突破 $1.5\times$ 硬上限（違反 C8b），凸顯單一指標排序難以處理多重結構限制（見圖 3）。

Table 1: 18 個真實使用者例題的完整結果（MILP / GRASP-LS / Greedy）。Gap 為 $(z_{\text{GRASP}} - z_{\text{MILP}}) / |z_{\text{MILP}}|$ 。所有 MILP 均回傳全域最佳解；GRASP-LS 100% hard-feasible，平均 gap 為 7.1%（12/18 為 0%，非零者集中於正餐情境）；Greedy 因餐型結構與鈉硬上限 0% 可行。

Instance	Cal range (kcal)	P^{min} (g)	MILP obj	GRASP obj	Gap (%)	MILP feas	GRASP feas	Greedy feas
U1_male_cut-latenight	106–318	11.2	27.98	27.98	0.0	Y	Y	N
U1_male_cut-light	318–529	22.4	35.80	35.80	0.0	Y	Y	N
U1_male_cut-regular	635–953	44.8	87.20	119.48	37.0	Y	Y	N
U2_male_bulk-latenight	166–497	13.5	40.60	40.60	0.0	Y	Y	N
U2_male_bulk-light	497–829	27.0	68.09	68.09	0.0	Y	Y	N
U2_male_bulk-regular	994–1491	54.0	163.53	173.55	6.1	Y	Y	N
U3_male_maintain-latenight	98–293	7.7	29.55	29.55	0.0	Y	Y	N
U3_male_maintain-light	293–489	15.4	36.21	36.21	0.0	Y	Y	N
U3_male_maintain-regular	587–880	30.8	74.04	74.85	1.1	Y	Y	N
U4_female_cut-latenight	73–220	8.3	32.91	32.91	0.0	Y	Y	N
U4_female_cut-light	220–366	16.6	41.17	41.17	0.0	Y	Y	N
U4_female_cut-regular	439–658	33.3	67.74	75.05	10.8	Y	Y	N
U5_female_maint-latenight	77–232	6.1	29.62	29.62	0.0	Y	Y	N
U5_female_maint-light	232–387	12.1	35.80	35.80	0.0	Y	Y	N
U5_female_maint-regular	464–697	24.2	63.20	88.82	40.5	Y	Y	N
U6_female_bulk-latenight	132–395	10.4	35.75	35.75	0.0	Y	Y	N
U6_female_bulk-light	395–659	20.9	57.55	57.55	0.0	Y	Y	N
U6_female_bulk-regular	791–1186	41.8	106.60	140.65	31.9	Y	Y	N

圖 2 以 U1（男·減脂·正餐）為例，比較三種解法在營養與成本上的表現：MILP / GRASP-LS 皆產出結構完整且各項指標達標的一餐；Greedy 因只看「蛋白質／價格比」而缺主餐、且鈉破硬上限，hard-infeasible。

U1 (male · cut · regular): nutrition & cost across solvers




Figure 2: U1 男·減脂·正餐情境（488 項真實全家商品）下三種解法之熱量、蛋白質、鈉與成本對比（虛線為對應限制）。MILP 解為結構完整的一餐：小菠蘿麵包（主餐）+ 蜜汁豬肉乾（配菜）+ 無加糖濃豆漿（飲料）+ 綜合水果軟糖（甜點），總價 NT\$110、693 kcal、45.6 g 蛋白質、667 mg 鈉，皆達標；GRASP-LS 取另一近似最優之結構餐（NT\$108）。Greedy 為榨取「蛋白質／價格比」挑出雞腿排 + 豬耳絲 + 豆漿，缺主餐（違反 C11）、鈉量 2168 mg 突破 $1.5\times$ 硬上限（違反 C8b），hard-infeasible。

7.2 Random Instances and Scalability

30 個隨機例題的結果如表 2 與圖 5 所示。MILP 在所有規模下均能求得最佳解；GRASP-LS 平均 optimality gap 為 **4.9%**，hard-feasible 比率 93%（28/30；兩個無解出現於 $|I| = 30, 50$ 之緊預算例題——在結構限制下，貪婪建構偶爾難以於低預算內湊齊「恰一主餐 + 蛋白」且熱量達標的組合，此時部署版會退回 MILP 後備）。需要說明的是：表 2 之分規模 gap 係各解法於各自可行子集上之平均（分母不同），因此 $|I| = 30, 50$ 因部分種子對 GRASP-LS 不可行而出現負值假象；以逐例（per-instance）對齊計算之平均 gap 仍為 **4.9%**。相對地，Greedy baseline 在加入餐型結構 (C10–C11) 與鈉硬上限 (C8b) 後幾乎全面失效：多數規模下 **0%** 可行，凸顯單一比值排序不足以滿足多重結構限制。




Figure 3: 18 個真實例題下 hard-feasible 比率。




Figure 4: 隨機例題規模對求解時間之影響（對數軸）。

Table 2: 隨機例題各規模下三種解法之平均表現（每規模 5 種子）。Greedy 之 gap 僅就「feasible 子集」計算；infeasible 例題以 feas 欄反映。

I	K	MILP		GRASP-LS			Greedy	
		obj	time (s)	obj	gap (%)	time (s)	feas	gap (%)
30	8	143.5	0.006	128.6	-10.3	0.017	0%	—
50	15	111.4	0.023	94.9	-14.8	0.058	20%	40
80	25	74.3	0.020	74.3	0.0	0.104	0%	—
120	35	58.6	0.075	62.4	6.5	0.576	0%	—
200	60	50.3	0.133	55.4	10.0	2.044	0%	—
300	90	42.1	0.227	44.1	4.6	4.156	0%	—

圖 4 顯示三種解法的 runtime 隨商品數成長之情形。MILP 從 6 ms ($|I| = 30$) 增長至 227 ms ($|I| = 300$)；GRASP-LS 從 17 ms 增長至約 4.2 秒；Greedy 始終在毫秒以下。雖然在本研究的測試規模下 Gurobi 求解速度極快，但 GRASP-LS 不依賴商業授權，較易嵌入 App 或 Edge 裝置，且具備可控的 anytime 性質（可隨時中斷並回傳目前最佳解）。

7.3 Stress-test Scenarios

表 3 彙整 2×2 壓力情境（預算 $\times$ 蛋白質目標，各 12 例）之結果。MILP 在全部 48 例中皆可行；GRASP-LS 在 46/48 例中找到可行解。兩個未找到可行解的案例皆落在「緊預算」條件下，分別出現於高蛋白與寬鬆蛋白質目標。關鍵觀察：真正推高 gap 的主要因素是「高蛋白目標」，而非單純的「緊預算」——增肌目標下 gap 為 7.4%（緊）／4.1%（寬），維持目標下僅 1.2%／1.4%；緊預算情境反而因可行域較小而求解更快（GRASP-LS 約 1.1–1.2 s vs. 寬預算 2.7–2.9 s）。即使在最嚴苛條件下，GRASP-LS 仍維持 $\leq 7.4\%$ 的 optimality gap 與秒級求解，驗證其穩健性。

Table 3: 2×2 壓力測試情境（各 12 例）：MILP/GRASP-LS 可行率、GRASP-LS 平均 optimality gap 與平均求解時間。

情境（預算 $\times$ 蛋白）	MILP feas	GRASP-LS feas	avg gap	GRASP-LS 時間
緊 $\times$ 高蛋白	12/12	11/12	7.35%	1.10 s
緊 $\times$ 寬鬆	12/12	11/12	1.22%	1.24 s
寬 $\times$ 高蛋白	12/12	12/12	4.12%	2.85 s
寬 $\times$ 寬鬆	12/12	12/12	1.36%	2.72 s

7.4 Comparison with an Uninformed Shopper

為估計模型相較於「現狀」（消費者自行盲選）的價值，本研究在真實 488 項商品上模擬一個無輔助購買基準：對每位使用者，於其預算內隨機抽取 2–4 件商品（不做任何營養最佳化）共 4000 次，統計達標情形（程式碼 src/run_extra_experiments.py）。結果見表 4：盲選平均僅約 4% 機率能同時滿足全部單餐限制，蛋白質下限達成率僅約 6%，鈉未超標比率約 63%；相對地，GRASP-LS 對所有使用者皆 100% 達標。值得強調的是，模型花費（平均約 NT\$109）與盲選平均花費（約 NT\$99）相當——模型並非透過少買來降低支出，而是在幾乎相同的花費下，將「整餐營養全達標」的機率由約 4% 提升至 100%，同時省去使用者逐項心算營養與預算的時間成本。




Figure 5: 隨機例題各規模平均 optimality gap (GRASP-LS vs. Greedy baseline)。

Table 4: 無輔助盲選基準 vs. 模型 (每位使用者 4000 次隨機抽樣)。百分比為盲選滿足該限制的比率；模型價為 GRASP-LS 之達標餐花費。

使用者	全達標	蛋白達標	鈉未超標	盲選均價	模型價 (達標)
U1 男·減脂	5.2%	1.6%	59.5%	NT\$103.7	NT\$108
U2 男·增肌	0.4%	1.3%	47.7%	NT\$121.6	NT\$149
U3 男·維持	3.2%	7.1%	71.7%	NT\$89.5	NT\$93
U4 女·減脂	9.8%	5.0%	70.1%	NT\$89.7	NT\$94
U5 女·維持	3.7%	14.6%	74.2%	NT\$80.6	NT\$85
U6 女·增肌	1.9%	4.0%	53.2%	NT\$110.9	NT\$124

7.5 Sensitivity Analysis

圖 6 顯示放寬預算為 NT\$220 後調整 β (蛋白質權重) 之成本-蛋白質權衡。 $\beta \leq 1$ 時模型以 NT\$109.5 的組合恰好滿足蛋白質下限 (45.6 g)；當 $\beta \geq 2$ 後，蛋白質的邊際效益超過較高價高蛋白商品的成本門檻，模型即改變推薦組合，蛋白質躍升至 92.8 g、花費升至 NT\$177； $\beta = 8$ 時更達 119.5 g / NT\$201.5。此「階梯式跳變」反映了 MILP 離散決策的本質。圖 7 顯示分層記憶之多樣性效應：將 $\gamma = 0$ 之最優解注入為近期歷史後， $\gamma = 0$ 時該餐 4 項全部再現；只要 $\gamma \geq 1$ ，分層懲罰即促使模型全數更換推薦品項 (重複數降為 0)，且因替代品同樣便宜，總花費不升反降 (NT\$109.5 $\rightarrow$ NT\$103)，顯示歷史懲罰能在「幾乎不犧牲成本」下顯著提升多樣性。




Figure 6: β 變化下的成本-蛋白質 trade-off。




Figure 7: γ 增大時近期商品再次出現次數遞減。

7.6 The Price of Diversity

若每次都回傳唯一最佳解，連續查詢容易得到幾乎相同的餐 (約\$5)。本研究以 Gurobi 解池 (solution pool, PoolSearchMode=2) 窮舉 ϵ -最佳解集合 $\mathcal{S}_\epsilon = \{s : z(s) \leq z^* + \epsilon\}$ ，以量化「犧牲多少最佳性可換得多少多樣性」。以一位男·維持·正餐使用者 (最便宜之達標餐 NT\$93) 為例，圖 8 顯示： $\epsilon = 0$ 僅 1 種最佳餐；放寬至 $\epsilon = 8$ (NT\$8) 即有 12 種結構完整且不同的餐點可選，平均僅多付 NT\$6.7； $\epsilon = 16$ 有 48 種、 $\epsilon = 32$ 更達 641

種，平均成本溢價分別為 NT\$12.8、NT\$20.9。這條曲線即「多樣性的代價」：在最佳解附近，取得多樣性的代價相當低——只需容忍個位數的成本，便可獲得十餘種同樣達標的餐。部署時本研究即以 $\epsilon = 8$ 對此集合取樣（以 GRASP-LS 近似 + 分層記憶長期去重），兼顧最佳性與「每次不同」的使用體驗。




Figure 8: 多樣性的代價：隨 ϵ -最佳取樣窗放寬，可選的不同達標餐數由 1 暴增至 641（藍柱），而平均成本溢價（紅線）僅緩升至約 NT\$21。在最佳解附近多樣性極廉。

7.7 Executable Recommendations

以 U1 男·減脂·正餐情境（70 kg，TDEE 2118 kcal，預算 NT\$120，單餐熱量區間 635–953 kcal、蛋白質下限 44.8 g、鈉上限 960 mg）為例。MILP 解為一份結構完整的餐：小菠蘿麵包（主餐 NT\$24）+ 蜜汁豬肉乾（配菜 NT\$32）+ 無加糖濃豆漿（飲料 NT\$28）+ 綜合水果軟糖（甜點 NT\$25），總價 NT\$110，攝取 693 kcal、45.6 g 蛋白質、667 mg 鈉——恰含一份主餐、至少一個蛋白質來源，並各含一份飲料與甜點，熱量、蛋白質、鈉皆達標。相較之下，以「蛋白質／價格比」貪取的 Greedy 取雞腿排 + 豬耳絲 + 豆漿（NT\$118、91 g 蛋白質）卻缺主餐且鈉達 2168 mg（超過 1.5× 硬上限），因此不可作為合理推薦。本模型的價值並不在於單純追求「最便宜」（一份結構餐約與一個便當同價），而在於固定預算下穩定產出「結構合理、營養達標、且每次不同」的一餐——這是單純比價或貪婪法無法同時兼顧的。

7.8 Interactive Web Application

為驗證模型之實際可用性，本研究實作一 Flask 互動式網頁應用（webapp/app.py）：使用者可於瀏覽器輸入生理資訊與用餐情境，後端即時呼叫 GRASP-LS（預設，含 ϵ -最佳多樣化取樣）或 Gurobi MILP 並回傳推薦清單。網頁以 cookie 維持分層的「口味記憶」佇列，連續使用時可觀察 MLFQ 式分層懲罰如何使推薦逐次產生差異；亦可透過 slider 調整 α, β, γ 。截圖見圖 9。

7.9 Discussion and Limitations

為何 Greedy 在新模型下 0% 可行？Greedy 依「蛋白質／價格比」此單一指標排序並逐項加入商品，必然偏好便宜、高蛋白密度的小型品（雞胸、雞腿、豆漿），結果同時違反多條硬性限制：缺主餐（C11）、品項全為小菜，且高蛋白加工品累積使鈉量突破 1.5× 硬上限（C8b）。這說明真實的餐食決策是「多重結構限制下的組合最佳化」，任何單一比值排序皆難以勝任——正是本研究 MILP / GRASP-LS 的價值所在。

為何 GRASP-LS 在「正餐」例題 gap 偶爾較大？加入「恰一份主餐 + 餐型結構」（C10–C11）後，正餐之可行組合較窄；當建構階段隨機選定的主餐不屬於最優解，且 LS 的 1-1 swap 鄰域無法一步到達該解時，便會卡在次優（最差約 40%）。可透過提高 K_{restart} 、加入「換主餐」與 2-2 swap 鄰域，或如部署版退回 MILP 後備來改善。

餐型結構大幅提升推薦真實性。早期版本在缺少 C10–C11 與角色標記時，可能推出「甜點當主菜」「三件零食湊一餐」「整瓶 1857 ml 豆漿」等雖營養達標但不符合實際用餐情境的組合。本研究以官方分類重定餐位角色、過濾家庭份、並加入「恰一主餐／至多一飲料一甜點」之結構硬限制後，推薦皆呈「一份主餐 + 配菜／飲料 + 至多一份甜點」的真實樣態，明顯提升可採用性。

資料品質與價格估計。488 項商品（581 項過濾家庭份後）之營養來自官方食品履歷，具高度可信度；價格則 124 項鮮食為促銷頁真實分級價，其餘 457 項因全家無公開單品價 API、且電商目錄為整箱價（78% 為多入



1 輸入你的條件

性別

男

年齡

22

身高 (cm)

175

體重 (kg)

70

活動量

中 (每週運動 1-3 次)

健康目標

維持現狀

情境模式

正餐

預算上限 (NT\$)

120

✓ 進階：模型權重設定

成本權重

α

1

蛋白質權重

β

0.5

多樣性權重

γ

6

求解器

GRASP-LS (本研究啟發式, ↕)

推薦這一餐

近期紀錄

2 推薦結果

本餐花費

NT\$115

求解器

GRASP

目標值

179.64

計算耗時

1596.9 ms

推薦清單

香蔥經典嫩雞胸

\$45

蛋白

154 熱量 kcal

22.4 蛋白 g

563 鈉 mg

經典黑炫牛奶酪鱈沙

\$50

蛋白

472 熱量 kcal

7.1 蛋白 g

174 鈉 mg

讚岐烏龍麵

\$20

主食

162 熱量 kcal

3.8 蛋白 g

216 鈉 mg

單餐限制達成度

熱量 (kcal)

達標

788.0 / 785-1178

蛋白質 (g)

達標

33.3 / 31-62

脂肪 (g)

達標

31.6 / 23-35

碳水 (g)

偏低

92.6 / 118-170

糖 (g)

偏高

40.2 / 0-26

鈉 (mg)

達標

953.0 / 0-960

模型在做什麼：

1 個人化熱量需求

以 Mifflin-St Jeor 公式，將性別、年齡、身高、體重、活動量換算成每日熱量 (TDEE)，再依減脂 -500、增肌 +300 調整。

2 情境縮放

依情境把每日熱量分配為三餐區間：

- 輕食約 15-25% (最多 3 項)
- 正餐約 30-45% (最多 5 項)
- 宵夜約 5-15% (最多 3 項)

3 最佳化求解

在 580+ 真實全家商品與優惠組合中，求出「min $\alpha \cdot$ 成本 - $\beta \cdot$ 蛋白 + $\gamma \cdot$ 歷史懲罰」，同時盡量滿足熱量、蛋白、糖、鈉與商品數量等限制。

4 分層口味記憶

使用多層佇列記憶：越近期吃過的商品 (及同類品項) 懲罰越重，越久遠的逐漸淡化，避免反覆推薦同樣的東西。

資料來源：全家便利商店食在購安心 API (foodsafety.family.com.tw) | 鮮食為促銷真實分級價、其餘為市售行情校正價 | 模型細節見 Final Report

Figure 9: 互動式網頁應用截圖 (已展開進階權重面板與「口味記憶」分層面板)：以「男·22 歲·175cm·70kg·中活動量·維持·正餐·預算 120 元」為輸入，GRASP-LS 回傳結構完整的一餐與各項營養達標度；「口味記憶」依新近程度分為「剛吃過／前幾餐／久未推」三層 (越深色 = 越近期 = 越不會再被推薦)。資料源自 488 項全家商品 (鮮食為真實分級價、其餘為市售行情校正價)。

裝)，改採依分類之市售行情校正值——這是本研究主要的資料限制。不過，敏感度測試顯示，將全部價格上下擾動 10% 後 U1 正餐之最優解結構 (主餐 + 配菜 + 飲料 + 甜點) 不變，模型對小幅價格誤差具穩健性。

權重選擇. 本研究預設 $(\alpha, \beta, \gamma) = (1, 0.5, 2)$ ，並透過敏感度分析說明各權重對解的影響。在實務部署上，這些權重可透過 App slider 介面開放使用者調整，讓使用者自行選擇「重視成本」或「重視蛋白質」；亦可結合個人歷史回饋自動學習。

8 Conclusions

本研究將便利商店餐食推薦問題形式化為一個同時包含優惠組合、個人化營養限制、餐型結構限制與分層多樣性懲罰的混合整數線性規劃，並以實際蒐集的 488 項全家商品資料 (鮮食為真實分級價、其餘為市售行情校正價) 為實證基礎。為兼顧求解品質與實務可用性，本研究自行設計 GRASP-LS 啟發式 (含結構感知建構與 ϵ -最佳多樣化取樣)，並以 18 個真實例題與 30 個隨機例題進行驗證。主要發現：(1) MILP 於毫秒到秒級求得全域最佳解；(2) GRASP-LS 100% hard-feasible，平均 optimality gap 為 7.1% (真實) / 4.9% (隨機)；(3) 加入餐型結構與鈉硬上限後，最簡單之 Greedy 法 0% 可行，凸顯在多重結構限制下進行組合最佳化的必要性；(4) 敏感度分析顯示 β 以「階梯式」控制成本-蛋白質權衡，分層歷史懲罰可在幾乎不漲價下消

10

除重複；(5) 以 Gurobi 解池量化「多樣性的代價」：在最佳解附近，容忍 NT\$8 即有 12 種達標餐可選、NT\$32 達 641 種，顯示在最佳解附近取得多樣性的成本相當低；(6) 實作 Flask 互動式 web 應用，含分層「口味記憶」與權重 slider，展示模型具備實際部署潛力。

未來研究可朝以下方向延伸：(a) 將模型推廣至「多日連續推薦」與動態庫存／到貨資訊；(b) 整合店面實際 OCR 商品標示，自動更新資料表；(c) 引入使用者點擊／拒絕回饋的線上學習機制，使 h_i 不僅反映過去推薦紀錄，也能學習使用者偏好；(d) 與外送 App 結合，將推薦範圍擴展至多通路（如 7-11、Hi-Life）以及不同時段限定品。